

DecisionOS v1.0.0   

DecisionOS v1.0.0 — Стратегический отчёт

Дата: 2026-08-19

Автор: Felix (@asurdev)

Коммит: c848e37 (docs: RELEASE-NOTES, WEEK4-RUNBOOK, WEEK4-SMOKE)

База: ROMA Execution Bridge v1.2.0 → DecisionOS v1.0.0


1. Исполнительное резюме

DecisionOS v1.0.0 — это **enterprise-ориентированная платформа принятия решений**, выращенная из ядра ROMA Execution Bridge. Платформа добавляет три слоя, отсутствовавшие в ROMA: **политики (Policy Engine)**, **тиринг (Tier Profiles)** и **аудитабельный Decision Trail** — превращая closed-loop executor в полноценную decision infrastructure для multi-tenant SaaS.

Ключевой результат: 13 новых модулей, 3 уровня цен (Start / Pro / Enterprise), 3 документа (Release Notes, Runbook, Smoke Test Plan), 8 smoke-тестов, обратная совместимость со всеми существующими API ROMA.

2. Архитектура

2.1. Принцип гейтирования



Правило ExecutionAllowed: Quota OK ∧ Cost OK ∧ Policy OK

2.2. Компонентная карта

Слой	Модули	Назначение
Policy	file	Оценка политик per-tenant, guard
	policy_engine.py, file	разрешённых
	policy_transition.py	переходов статусов
Tier	file	Start / Pro / Enterprise
	tier_profiles.py, file tier_gate.py,	с лимитами по jobs, GPU, concurrency,
	file tiers.json	retention
Audit		5 типов событий
	file	(policy_allowed/
	audit_events.py, file	denied,
	decision_service.py, file	transition_denied,
	file	tool_call_allowed/
	decision_store.py	denied),
		персистентность в PostgreSQL

Слой	Модули	Назначение
Routing	file	Декомпозиция монолитного роутера
	router_decisions.py, file router_jobs.py	ROMA → отдельные decision/job endpoints
Enterprise	file white_label.py,	White-label конфигурация,
	file error_model.py	унифицированная модель ошибок с machine-readable кодами

2.3. Доменные сущности

- **DecisionRequest** — входящий запрос (tenant, action, context)
- **DecisionRecord** — результат (allowed/denied, reason, policy_name)
- **ExecutionJob** — задание (queued → running → completed/failed/cancelled)
- **PolicyDecision** — вердикт policy engine
- **UsageEvent** — событие потребления (для биллинга)

3. Тип-модель

Параметр	Start	Pro	Enterprise
max_jobs_month	50	150	∞
max_gpu_seconds_month	^x 36 000	^x 180 000	^g ∞
max_concurrent	5	20	100
audit_retention_days	7	90	∞
white_label	^x	^x	^g
policy_engine	default	default	custom
ai_tools	basic	full	full
SSO			

4. Policy Engine

Интерфейс

```
evaluate_policies(tenant_id: str, action: str, context: dict) -> {
    "result": "allowed" | "denied",
    "reason": str,
    "policy_name": str
}
```

Default Policy Profile

Действие	Правило
read:* (basic tools)	Allowed
submit	Allowed if quota available
retry	Allowed only if job status = failed
cancel	Denied if status = completed/failed/cancelled
tool_call (AI)	Denied if tenant key missing

Transition Guard

Transition	Статус
queued → running	
running → completed	
running → failed	
queued → cancelled	
running → cancelled	
completed → any	transition_denied
cancelled → any	transition_denied
failed → any (except retry flow)	transition_denied

5. Audit Events

5 типов событий с полным контекстом (tenant_id, action, result, reason, policy_name, timestamp):

- policy_allowed
- policy_denied
- transition_denied
- tool_call_allowed
- tool_call_denied

Все события пишутся в PostgreSQL, retention зависит от тира.

6. Error Model

Унифицированная модель ошибок с machine-readable кодами:

Код	HTTP	Описание
quota_exceeded	429	Лимит тира исчерпан
cost_over_budget	402	Превышен бюджет
policy_violation	403	Политика запрещает действие
transition_denied	409	Недопустимый переход статуса
tool_not_allowed	403	AI tool запрещён
tenant_not_found	404	Тенант не найден

7. Технические метрики

Метрика	Значение
Новых модулей	13
Строк кода (DecisionOS-специфичных)	~5 400

Метрика	Значение
Коммитов в цепочке DecisionOS	3 (schema → foundation → docs)
Smoke-тестов	8/8 passed
Тир-уровней	3 (Start, Pro, Enterprise)
Типов аудит-событий	5
Policy engine interface	1 (evaluate_policies)
Обратная совместимость	Полная (все API ROMA сохранены)

8. Стратегическая дорожная карта (Next 90 дней)

Q3 2026 (Week 5-8) — Production Hardening

- ☐ Stripe Checkout + CloudPayments → live payment flow
- ☐ Enterprise SSO (OIDC/SAML)
- ☐ PostgreSQL → TimescaleDB migration для audit_events (hypertable)
- ☐ SLO/SLI дашборд в Grafana (p99 latency, error rate, quota utilisation)
- ☐ Rate limiting per-tenant (token bucket)

Q4 2026 (Week 9-16) — GTM & Scale

- ☐ Plugin marketplace MVP
- ☐ White-label onboarding flow (Enterprise tier)
- ☐ AI chat assistant для policy authoring
- ☐ Multi-region (EU, US) deployment
- ☐

9. Риски и митигация

Риск	Вероятность	Митигация
Policy engine bottleneck (single Python eval)	Средняя	Cache policy decisions per tenant (TTL 60s)
PostgreSQL — audit volume growth	Высокая	TimescaleDB hypertables + tier-based retention
Enterprise white-label — кастомизация требует per-tenant deploy	Средняя	Feature flags + tenant_config в tiers.json
Stripe/CloudPayments — compliance (PCI DSS)	Средняя	Stripe Elements / CloudPayments widget (токенизация на стороне провайдера)

10. Заключение

DecisionOS v1.0.0 — это **фундамент enterprise decision infrastructure**. Платформа вышла из фазы «feature-complete executor» (ROMA) в фазу «multi-tenant, policy-gated decision platform» с чёткой тир-моделью, аудит-трейлом и обратной совместимостью. Следующий логический шаг — **production hardening** (live payments, SSO, observability) и подготовка к **GTM** (plugin marketplace, white-label onboarding, multi-region).

Статус документа: Final

Следующий пересмотр: 2026-09-19 (30 дней)